

MVP DE ENGENHARIA DE DADOS

Fatores associados à nota final dos estudantes

Databricks Free Edition | Python/PySpark | Delta Lake | Unity Catalog

Nome: Jeferson Ferreira Fagundes

Matrícula: 4052026000082

Data: 09/2026

Dataset: Student Productivity & Distraction Dataset, extraído da Kaggle.

Fonte: https://raw.githubusercontent.com/jefersonferreirafagundes-eng/MVP-ML-Analytics/refs/heads/main/student_productivity_distraction_dataset_20000.csv

<https://github.com/jefersonferreirafagundes-eng/MVP-Engenharia-de-Dados-New/blob/main/README.md>

MVP de Engenharia de Dados - Fatores associados à nota final dos estudantes

Visão geral

Este MVP implementa um pipeline no Databricks Free Edition com Python/PySpark, Delta Lake e Unity Catalog. O objetivo é investigar quais características de rotina, estudo, frequência, foco e uso de tecnologia apresentam associação com final_grade (nota final).

Correlação não demonstra causalidade. Os resultados deste MVP não permitem afirmar que uma variável causa aumento ou redução da nota.

1. Contexto de Negócio e Perguntas

Problema

O problema de negócio deste MVP consiste em compreender, a partir dos dados disponíveis, se características relacionadas à rotina dos estudantes, hábitos de estudo, frequência, foco, realização de atividades, bem-estar e uso de tecnologias apresentam associação com a nota final (final_grade). A análise busca transformar dados brutos em informação analítica organizada e rastreável, sem atribuir causalidade a relações que são apenas observacionais.

Perguntas orientadoras

1. Quais variáveis numéricas apresentam maior associação linear com final_grade?
2. Estudo, frequência, foco e atividades concluídas apresentam associação linear com a nota final?
3. Celular, redes sociais, YouTube, jogos e o tempo agregado de entretenimento digital apresentam associação linear com a nota final?
4. Sono e exercício apresentam associação linear com a nota final?
5. Existem diferenças descritivas nas médias de nota, estudo, frequência e foco entre os grupos de gênero?

Dados brutos

A execução no Databricks confirmou a utilização de 5.999 registros, cada um representando um estudante, e 18 atributos originais. Esse conjunto reúne variáveis demográficas, comportamentais, acadêmicas e de rotina, permitindo estruturar diferentes perspectivas de análise sobre o desempenho final.

Atributos originais: student_id, age, gender, study_hours_per_day, sleep_hours, phone_usage_hours, social_media_hours, youtube_hours, gaming_hours, breaks_per_day, coffee_intake_mg, exercise_minutes,

assignments_completed, attendance_percentage, stress_level, focus_score, final_grade e productivity_score.

Arquivo analisado: student_productivity_distraction_dataset_20000.csv.

Fonte e licença

Dataset: Student Productivity & Distraction Dataset, extraído da Kaggle.

Fonte: https://raw.githubusercontent.com/jefersonferreirafagundes-eng/MVP-ML-Analytics/refs/heads/main/student_productivity_distraction_dataset_20000.csv

Carga no Databricks em:

/Volumes/workspace/mvp_raw/input_files/student_productivity_distraction_dataset_20000.csv

2. Carga dos Dados

A ingestão foi executada no Databricks Free Edition. O arquivo CSV foi disponibilizado em um Managed Volume do Unity Catalog, no caminho /Volumes/workspace/mvp_raw/input_files. Essa decisão mantém o arquivo de entrada identificado no ambiente de dados e estabelece um ponto de origem explícito para o pipeline.

Fluxo de ingestão: arquivo CSV → Managed Volume no Unity Catalog → camada Bronze em formato Delta.

A tabela workspace.mvp_bronze.student_productivity_raw constitui a primeira representação persistida dos dados no pipeline. Nessa etapa, o objetivo principal é preservar o conteúdo recebido, acrescentando os metadados necessários à rastreabilidade da ingestão, antes das regras de limpeza e transformação aplicadas nas etapas seguintes.

3. Modelagem e Catálogo de Dados

A organização do pipeline segue a Arquitetura Medalhão, estruturada nas camadas Raw → Bronze → Silver → Gold. Essa separação permite distinguir claramente a origem do arquivo, sua persistência inicial, o tratamento de qualidade e a disponibilização dos dados preparados para análise. Com isso, cada etapa possui responsabilidade definida e pode ser auditada de forma independente.

Raw

workspace.mvp_raw.input_files

Bronze

workspace.mvp_bronze.student_productivity_raw — camada destinada à preservação do dado recebido e dos metadados de ingestão, servindo como referência para as transformações posteriores.

Silver

- workspace.mvp_silver.student_productivity_clean
- workspace.mvp_silver.data_quality_summary

Na camada Silver são realizadas as atividades de preparação dos dados: verificação de duplicidades e valores nulos, adequação de tipos, padronização, avaliação dos domínios observados e criação da variável derivada `entertainment_hours`. Também é persistido um resumo de qualidade para registrar as verificações efetuadas.

Gold

- workspace.mvp_gold.student_performance
- workspace.mvp_gold.correlation_with_final_grade
- workspace.mvp_gold.performance_by_gender

Na camada Gold foi adotado um modelo analítico flat por conceito, com um registro por estudante na tabela principal. Essa estrutura facilita consultas e análises sobre desempenho, evitando que o usuário analítico precise reconstruir as etapas de tratamento realizadas anteriormente.

Catálogo

As tabelas e os campos foram documentados no Unity Catalog com informações de descrição, tipo de dado e domínio observado. O catálogo funciona, neste MVP, como mecanismo de governança e compreensão do dado: além de indicar onde cada ativo está armazenado, explicita o significado e as características dos principais atributos utilizados na análise. Exemplos:

Campo	Tipo	Domínio observado
student_id	int	1--5999
age	int	17--29
gender	string	Female, Male, Other
study_hours_per_day	double	0,5--10
sleep_hours	double	3--10
phone_usage_hours	double	0,5--12
social_media_hours	double	0--8
youtube_hours	double	0--6
gaming_hours	double	0--6
attendance_percentage	double	40,01--99,97
stress_level	int	1--10

focus_score	int	30--99
productivity_score	double	1,91--99,9
final_grade	double	40,0--99,99

Dicionário de dados

Para melhor entendimento, descrevemos abaixo, já traduzidas, algumas das variáveis que serão analisadas neste trabalho:

Coluna	Tipo esperado	Descrição	Será usada no modelo?	Observações
age	Numérica	Idade do estudante	Sim	Variável demográfica
gender	Categórica	Gênero informado	Sim	Será codificada com OneHotEncoder
study_hours_per_day	Numérica	Horas diárias de estudo	Sim	Hipótese de associação positiva com a nota
sleep_hours	Numérica	Horas de sono	Sim	Pode indicar equilíbrio ou privação de sono
phone_usage_hours	Numérica	Horas de uso do telefone	Sim	Indicador de possível distração digital
social_media_hours	Numérica	Horas em redes sociais	Sim	Indicador de uso digital não acadêmico
youtube_hours	Numérica	Horas no YouTube	Sim	Pode incluir uso educacional ou entretenimento
gaming_hours	Numérica	Horas em jogos	Sim	Indicador de entretenimento digital
final_grade	Numérica	Nota final do estudante	Alvo	Variável a ser prevista

Linhagem

A linhagem registrada no Unity Catalog evidencia a transformação de `workspace.mvp_silver.student_productivity_clean` em `workspace.mvp_gold.student_performance` e associa o notebook `03_gold_analysis` ao processo. Essa evidência é importante porque permite identificar de onde os dados analíticos vieram e qual etapa computacional participou de sua geração, fortalecendo a rastreabilidade do pipeline.

4. Pipeline de Dados

- `00_setup` — prepara a estrutura do ambiente, criando os schemas correspondentes às camadas Raw, Bronze, Silver e Gold. Essa etapa estabelece previamente os espaços lógicos em que os diferentes estados do dado serão armazenados.
- `01_bronze_ingestion` — realiza a leitura do CSV a partir do volume, executa validações iniciais, registra metadados de ingestão e persiste o conteúdo na camada Bronze em formato Delta. O propósito é criar uma cópia controlada e rastreável do dado recebido.
- `02_silver_quality` — concentra o tratamento e a verificação da qualidade: analisa duplicidades e valores nulos, ajusta tipos, verifica domínios, padroniza os dados, cria `entertainment_hours` e persiste tanto a tabela limpa quanto o resumo de qualidade na camada Silver.
- `03_gold_analysis` e `04_catalog_lineage` — o primeiro notebook produz a tabela analítica Gold, calcula as correlações com `final_grade` e consolida a análise descritiva por gênero. O segundo documenta os ativos no Unity Catalog e permite evidenciar a linhagem entre as tabelas Silver e Gold. Em conjunto, essas etapas fecham o fluxo entre ingestão, tratamento, análise e governança.

5. Qualidade de Dados

A qualidade foi avaliada sobre os 18 atributos originais e em três dimensões diretamente verificadas no MVP: completude, unicidade da chave de estudante e consistência dos valores observados. O objetivo foi identificar problemas que pudessem comprometer as análises antes da construção da camada Gold.

Completude

Completude — os 18 atributos apresentaram zero valores nulos nos 5.999 registros analisados. Portanto, não houve necessidade de aplicar técnicas de imputação.

Unicidade

- Registros totais: 5.999.
- `student_id` distintos: 5.999.

- Duplicidades de student_id: 0. A correspondência entre o total de registros e o total de identificadores distintos indica unicidade da chave student_id no conjunto processado.

Consistência

Consistência — foram examinados valores mínimos e máximos e os domínios observados dos atributos. Nas verificações implementadas, não foram encontrados valores fora dos limites estruturais avaliados que justificassem exclusão automática.

Variável derivada

Variável derivada — $\text{entertainment_hours} = \text{social_media_hours} + \text{youtube_hours} + \text{gaming_hours}$.

A variável foi criada para representar, de forma agregada, o tempo dedicado às três atividades digitais de entretenimento presentes no dataset e permitir verificar se o conjunto dessas atividades apresentava associação linear com final_grade.

6. Análise de Dados

Pergunta 1 — Quais variáveis numéricas apresentam maior associação linear com a nota final?

Posição Variável	Correlação
1 youtube_hours	-0,0379
2 gaming_hours	+0,0332
3 stress_level	-0,0288
4 study_hours_per_day	-0,0263
5 sleep_hours	+0,0217
6 attendance_percentage	-0,0188
7 assignments_completed	+0,0154
8 productivity_score	-0,0126
9 focus_score	-0,0098
10 age	+0,0094

A maior correlação em valor absoluto foi observada para youtube_hours (-0,0379), seguida de gaming_hours (+0,0332), stress_level (-0,0288) e study_hours_per_day (-0,0263). Como todos os coeficientes estão muito próximos de zero, os dados processados não evidenciam associação linear relevante entre qualquer uma das variáveis avaliadas isoladamente e final_grade. Os sinais positivo ou

negativo indicam apenas a direção da correlação calculada; diante de magnitudes tão pequenas, não devem ser interpretados como evidência de efeito prático ou causal.

Pergunta 2 — Estudo, frequência, foco e atividades concluídas estão associados à nota?

- estudo: -0,0263
- frequência: -0,0188
- foco: -0,0098
- atividades: +0,0154

Os coeficientes encontrados para estudo (-0,0263), frequência (-0,0188), foco (-0,0098) e atividades concluídas (+0,0154) são muito próximos de zero. Assim, neste conjunto de 5.999 registros, essas variáveis, quando examinadas individualmente por correlação linear, não apresentam associação relevante com a nota final. O resultado não significa que estudo, frequência, foco ou realização de atividades sejam irrelevantes para a aprendizagem em geral; significa apenas que o dataset analisado não mostrou relação linear relevante entre essas medidas e final_grade.

Pergunta 3 — Celular, redes sociais, YouTube, jogos e entretenimento digital estão associados à nota?

- celular: -0,0032
- redes sociais: +0,0016
- YouTube: -0,0379
- games: +0,0332
- entretenimento digital: -0,0011

Também nesse grupo os coeficientes são muito baixos: celular (-0,0032), redes sociais (+0,0016), YouTube (-0,0379), jogos (+0,0332) e entertainment_hours (-0,0011). A variável agregada de entretenimento digital ficou praticamente em zero, e mesmo os maiores valores individuais — YouTube e jogos — permanecem de magnitude muito pequena. Portanto, os dados não sustentam uma associação linear relevante entre o tempo registrado nessas atividades digitais e final_grade. Não é possível concluir, a partir desses coeficientes, que aumentar ou reduzir qualquer dessas atividades provoque alteração na nota.

Pergunta 4 — Sono e exercício estão associados à nota?

- sono: +0,0217
- exercício: +0,0022

Sono apresentou correlação de +0,0217 e exercício, de +0,0022. Ambos os valores são muito próximos de zero e, portanto, não evidenciam associação linear relevante com final_grade no conjunto analisado. A interpretação deve permanecer restrita ao que foi medido: os resultados não demonstram ausência de

importância de sono ou exercício para o estudante, apenas ausência de relação linear relevante com a nota final neste dataset.

Pergunta 5 — Existem diferenças descritivas nas médias entre os grupos de gênero?

Gênero	Estudantes	Nota média	Estudo médio	Frequência	Foco médio
Female	2.868	70,21	5,20	69,90	63,94
Male	2.897	70,25	5,20	69,29	64,28
Other	234	69,71	5,03	68,79	65,30

As médias de `final_grade` foram 70,21 para Female, 70,25 para Male e 69,71 para Other. A diferença entre a maior e a menor média foi de apenas 0,54 ponto. As médias de estudo, frequência e foco também se mantiveram próximas entre os grupos. A análise é exclusivamente descritiva: ela mostra como os registros estão distribuídos no dataset, mas não fornece base para atribuir ao gênero qualquer efeito causal sobre desempenho, estudo, frequência ou foco.

Discussão geral

Considerando os 5.999 registros processados, o principal achado é a ausência de associações lineares relevantes entre `final_grade` e as variáveis numéricas avaliadas isoladamente. A maior correlação absoluta foi de apenas 0,0379. Esse resultado é importante porque evita conclusões intuitivas não sustentadas pelos dados, como afirmar que mais horas de estudo necessariamente elevaram as notas ou que maior uso de YouTube, jogos ou celular necessariamente as reduziu. O MVP demonstra, portanto, que a infraestrutura de dados foi capaz de organizar, qualificar e analisar o conjunto, mas que as variáveis disponíveis, na forma e no recorte observados, têm baixo poder explicativo linear sobre a nota final. Relações não lineares, interações entre variáveis ou fatores não presentes no dataset permanecem fora do alcance desta análise.

7. Autoavaliação

Objetivos atingidos

Considerando que tenho trabalhado essa base de dados nas 2 disciplinas anteriores do curso, não tive dificuldades em elaborar este último MVP. Inicialmente o objetivo não estava claro, não tínhamos um template para seguir, mas com as sessões de tira dúvidas as questões foram muito bem esclarecidas pelos professores. O trabalho realizado produziu um MVP que implementou um pipeline de engenharia de dados em ambiente de nuvem no Databricks Free Edition, estruturado segundo a Arquitetura Medalhão. Foram criadas e persistidas tabelas Delta nas camadas Bronze, Silver e Gold, realizadas verificações de qualidade, documentados ativos no Unity Catalog, registrada a linhagem Silver → Gold e produzidas análises diretamente relacionadas às perguntas definidas no contexto de negócio. Dessa forma, o trabalho

não se limitou ao cálculo de correlações: ele demonstrou o ciclo de ingestão, tratamento, governança, rastreabilidade e disponibilização analítica dos dados.

Dificuldades

A implementação exigiu ajustes específicos do Databricks e do Unity Catalog, principalmente na organização dos metadados de origem e na estruturação dos ativos entre volumes, schemas e tabelas.

Limitações

A análise é observacional e baseada predominantemente em correlações lineares. Correlação não demonstra causalidade, e os coeficientes encontrados foram muito baixos. Além disso, os resultados dependem das variáveis existentes no dataset e da forma como elas foram coletadas e representadas. O MVP não testa mecanismos causais, não acompanha os mesmos estudantes longitudinalmente e não permite concluir que alterações em hábitos específicos produziram mudanças na nota final. Consequentemente, as conclusões devem ser interpretadas como evidências descritivas e associativas restritas a este conjunto de dados.

Trabalhos futuros

Uma evolução do projeto pode incorporar novas fontes educacionais, dados longitudinais e variáveis adicionais devidamente anonimizadas, permitindo analisar dimensões não representadas no conjunto atual. Também podem ser investigadas relações não lineares e interações entre variáveis, além da inclusão de testes automatizados de qualidade e de um pipeline incremental para cenários com atualização contínua. Modelos preditivos podem ser acrescentados em uma etapa posterior, desde que se mantenha explícita a distinção entre capacidade de predição, associação estatística e evidência causal. Essa evolução permitiria avaliar se combinações de atributos oferecem informação que não aparece nas correlações individuais observadas neste MVP.

Apêndice A - Evidências visuais da execução

As evidências abaixo foram selecionadas do documento de screenshots produzido durante a execução do MVP no Databricks e no GitHub.





Figura A.3 - Carga do CSV no Unity Catalog Volume.

The top screenshot shows a Databricks notebook cell with the following code:

```
BRONZE_TABLE = "workspace.mvp_bronze.student_productivity_raw"

df_bronze.write \
    .format("delta") \
    .mode("overwrite") \
    .option("overwriteSchema", "true") \
    .saveAsTable(BRONZE_TABLE)

print("Tabela Bronze persistida com sucesso:")
print(BRONZE_TABLE)
```

The middle screenshot shows a notebook cell with the following code:

```
df_bronze_check = spark.table(BRONZE_TABLE)

print("=== VALIDAÇÃO DA BRONZE ===")
print("Tabela:", BRONZE_TABLE)
print("Quantidade de registros:", df_bronze_check.count())
print("Quantidade de colunas:", len(df_bronze_check.columns))

display(df_bronze_check.limit(10))
```

The bottom screenshot shows the Databricks Catalog Explorer for the 'mvp_bronze' schema. The 'Tables' tab is selected, showing a table named 'student_productivity_raw' with the following schema:

student_id	age	gender	study_hours_per_day	sleep_hours	phone_usage_hours	social_media_hours
2	20	Male	6.14	6.58	5.48	1.51
3	29	Female	4.98	3.25	4.83	3.63
4	27	Female	3.19	4.58	19.06	3.95
5	24	Male	7.67	6.21	3.02	1.59

Figura A.6 - Persistência e validação da camada Bronze.

#	column	valores_nulos	1.2 percentual_nulos
1	student_id	0	0
2	age	0	0
3	gender	0	0
4	study_hours_per_day	0	0
5	sleep_hours	0	0
6	phone_usage_hours	0	0
7	social_media_hours	0	0
8	youtube_hours	0	0
9	gaming_hours	0	0
10	breaks_per_day	0	0
11	coffee_intake_mg	0	0
12	exercise_minutes	0	0
13	assignments_completed	0	0
14	attendance_percentage	0	0

```

# Conversão dos tipos para preparação do camada Silver

integer_cols = [
    "student_id",
    "age",
    "breaks_per_day",
    "coffee_intake_mg",
    "exercise_minutes",
    "assignments_completed",
    "stress_level",
    "focus_score"
]

double_cols = [
    "study_hours_per_day",
    "sleep_hours",
    "phone_usage_hours",
    "social_media_hours",
    "youtube_hours",
    "gaming_hours",
    "attendance_percentage",
    "final_grade",
    "productivity_score"
]

```


```

print("=== TIPOAGEM CONCLUÍDA ===")
df_typed.printSchema()

|-- student_id: integer (nullable = true)
|-- age: integer (nullable = true)
|-- gender: string (nullable = true)
|-- study_hours_per_day: double (nullable = true)
|-- sleep_hours: double (nullable = true)
|-- phone_usage_hours: double (nullable = true)
|-- social_media_hours: double (nullable = true)
|-- youtube_hours: double (nullable = true)
|-- gaming_hours: double (nullable = true)
|-- breaks_per_day: integer (nullable = true)
|-- coffee_intake_mg: integer (nullable = true)
|-- exercise_minutes: integer (nullable = true)
|-- assignments_completed: integer (nullable = true)
|-- attendance_percentage: double (nullable = true)
|-- stress_level: integer (nullable = true)
|-- focus_score: integer (nullable = true)
|-- final_grade: double (nullable = true)
|-- productivity_score: double (nullable = true)
|-- _ingestion_ts: timestamp (nullable = true)
|-- _source_file: string (nullable = true)

```

Figura A.8 - Análise de completude dos atributos.



```
df_silver_check = spark.table(SILVER_TABLE)

print("=== VALIDAÇÃO DA SILVER ===")
print("Tabela:", SILVER_TABLE)
print("Registros:", df_silver_check.count())
print("Colunas:", len(df_silver_check.columns))

print("\nSchema:")
df_silver_check.printSchema()

display(df_silver_check.limit(10))

> See performance (2)

df_silver_check: pyspark.sql.connect.dataframe.DataFrame ~ [student_id: integer, age: integer ... 19 more fields]
```

=== VALIDAÇÃO DA SILVER ===

Tabela: workspace.mvp_silver.student_productivity_clean

Registros: 5999

Colunas: 21

Schema:

```
root
 |-- student_id: integer (nullable = true)
 |-- age: integer (nullable = true)
 |-- gender: string (nullable = true)
 |-- study hours per day: double (nullable = true)
```




Figura A.12 - Persistência e validação da camada Silver.

The screenshot shows the Databricks workspace interface. The left sidebar contains navigation options like Home, Learn, Workspace, Recents, Catalog, Jobs & Pipelines, Compute, Discover, Marketplace, SQL Editor, Queries, Dashboards, Genie Agents, Alerts, Query History, SQL Warehouses, and Engineering. The main area displays a table with the following data:

	A ₂ variavel	1.2 correlacao	1.2 forca_associacao
1	youtube_hours	-0.0379	0.0379
2	gaming_hours	0.0332	0.0332
3	stress_level	-0.0288	0.0288
4	study_hours_per_day	-0.0263	0.0263
5	sleep_hours	0.0217	0.0217
6	attendance_percentage	-0.0188	0.0188
7	assignments_completed	0.0154	0.0154
8	productivity_score	-0.0126	0.0126
9	focus_score	-0.0098	0.0098
10	age	0.0094	0.0094
11	breaks_per_day	-0.0083	0.0083
12	coffee_intake_mg	0.0057	0.0057
13	phone_usage_hours	-0.0032	0.0032
14	exercise_minutes	0.0022	0.0022
15	socialmedia_hours	0.0016	0.0016

16 rows · 0.918s runtime · Refreshed Now

The screenshot shows the Databricks workspace interface with a Python code editor. The code is as follows:

```

# Persistência do ranking de correlações na camada Gold

CORRELATION_TABLE = (
    "workspace.mpp_gold.correlation_with_final_grade"
)

(
    df_ranking.write
    .format("delta")
    .mode("overwrite")
    .option("overwriteSchema", "true")
    .saveAsTable(CORRELATION_TABLE)
)

print("Tabela de correlações persistida com sucesso!")
print(CORRELATION_TABLE)

```

See performance (1) · Checked for improvements

Tabela de correlações persistida com sucesso:
workspace.mpp_gold.correlation_with_final_grade

The screenshot shows the Databricks workspace interface. The left sidebar contains navigation options like Home, Learn, Workspace, Recents, Catalog, Jobs & Pipelines, Compute, Discover, Marketplace, SQL Editor, Queries, Dashboards, Genie Agents, Alerts, Query History, SQL Warehouses, and Engineering. The main area displays a table with the following data:

	A ₂ dimensao	A ₂ variavel	1.2 correlacao
1	Estudo	study_hours_per_day	-0.0263
2	Frequência	attendance_percentage	-0.0188
3	Foco	focus_score	-0.0098
4	Atividades	assignments_completed	0.0154
5	Celular	phone_usage_hours	-0.0032
6	Redes sociais	social_media_hours	0.0016
7	YouTube	youtube_hours	-0.0379
8	Games	gaming_hours	0.0332
9	Entretenimento digit...	entertainment_hours	-0.0011
10	Sono	sleep_hours	0.0217
11	Exercício	exercise_minutes	0.0022

11 rows · 6.418s runtime · Refreshed Now

Figura A.15 - Ranking de correlações com final_grade.

The screenshot shows a Databricks notebook with a table of student performance data. The table has 7 columns: gender, estudantes, 1.2 nota_media, 1.2 horas_estudo_media, 1.2 frequencia_media, 1.2 foco_medio, and 1.2 entretenimento_medio. The data is grouped by gender (Female, Male, Other).

gender	estudantes	1.2 nota_media	1.2 horas_estudo_media	1.2 frequencia_media	1.2 foco_medio	1.2 entretenimento_medio
Female	2868	70.21	5.2	69.9	63.94	
Male	2897	70.25	5.2	69.29	64.28	
Other	234	69.71	5.03	68.79	65.3	

The screenshot shows a Databricks notebook with a table of student performance data. The table has 7 columns: gender, estudantes, 1.2 nota_media, 1.2 horas_estudo_media, 1.2 frequencia_media, 1.2 foco_medio, and 1.2 entretenimento_medio. The data is grouped by gender (Female, Male, Other).

gender	estudantes	1.2 nota_media	1.2 horas_estudo_media	1.2 frequencia_media	1.2 foco_medio	1.2 entretenimento_medio
Female	2868	70.21	5.2	69.9	63.94	
Male	2897	70.25	5.2	69.29	64.28	
Other	234	69.71	5.03	68.79	65.3	

The screenshot shows a Databricks notebook with a table of student performance data. The table has 7 columns: gender, estudantes, 1.2 nota_media, 1.2 horas_estudo_media, 1.2 frequencia_media, 1.2 foco_medio, and 1.2 entretenimento_medio. The data is grouped by gender (Female, Male, Other).

gender	estudantes	1.2 nota_media	1.2 horas_estudo_media	1.2 frequencia_media	1.2 foco_medio	1.2 entretenimento_medio
Female	2868	70.21	5.2	69.9	63.94	
Male	2897	70.25	5.2	69.29	64.28	
Other	234	69.71	5.03	68.79	65.3	

Figura A.16 - Análise descritiva por gênero.






Figura A.17 - Catálogo e documentação da tabela Gold.






Figura A. 18 - Linhagem Silver → Gold no Unity Catalog.

```

# Validação da tabela de qualidade
df_quality_check = spark.table(QUALITY_TABLE)

print("=== VALIDAÇÃO DA TABELA DE QUALIDADE ===")
print("Tabela:", QUALITY_TABLE)
print("Registros:", df_quality_check.count())
print("Colunas:", len(df_quality_check.columns))

display(df_quality_check)

> See performance (2)
df_quality_check: pyspark.sql.DataFrame [atributo: string, total_registros: long ... 3 more fields]
=== VALIDAÇÃO DA TABELA DE QUALIDADE ===
Tabela: workspace.mvp_silver.data_quality_summary
Registros: 18
Colunas: 5

Table
+-----+-----+-----+-----+-----+
| atributo | total_registros | valores_nulos | percentual_nulos | valores_distintos |
+-----+-----+-----+-----+-----+
| study_hours_per_day | 5999 | 0 | 0 | 951 |
| sleep_hours | 5999 | 0 | 0 | 701 |
| phone_usage_hours | 5999 | 0 | 0 | 1144 |
| social_media_hours | 5999 | 0 | 0 | 801 |

```

Overview Details Permissions Policies

AI generate Add

Filter tables

Tables 2 Volumes 0 Models 0 Functions 0 Secrets 0 Services 0 Connections 0

Name	Owner	Created at	Popularity	Comment
data_quality_summary	jefersonfeneira.fagundes@gmail.com	Aug 28, 2026, 04:31 PM		
student_productivity_clean	jefersonfeneira.fagundes@gmail.com	Aug 28, 2026, 03:52 PM		Camada Silver. Dados d...

About this schema
Owner: jefersonfeneira.fagundes@gmail.com

```

spark.sql("""
COMMENT ON TABLE workspace.mvp_silver.data_quality_summary IS
'Resumo das métricas de qualidade dos 18 atributos originais,
incluindo completude e quantidade de valores distintos.'
""")

print("Tabela data_quality_summary documentada.")

> See performance (1)
Tabela data_quality_summary documentada.

```

Figura A.19 - Resumo de qualidade persistido na Silver.

data quality summary

Overview Sample Data Details Permissions Policies History Lineage Insights Quality

Description

Resumo das métricas de qualidade dos 18 atributos originais, incluindo completude e quantidade de valores distintos.

Column	Type	Popularity	Comment	Tags	Column masking
atributo	string	100%			
total_registros	bigint	100%			
valores_nulos	bigint	100%			
percentual_nulos	double	100%			
valores_distintos	bigint	100%			

About this table

Owner: jeffersonferreira.fagundes@gmail.com

Type: Managed

Data source: Delta

jeffersonferreira.fagundes-eng / MVP-Engenharia-de-Dados-Novo

Código Problemas Solicitações de pull Ações Projetos Wiki Segurança e qualidade Percepções Configurações

MVP-Engenharia-de-Dados-Novo Público

Configure o GitHub Copilot

Use o programador em pares com IA do GitHub para obter sugestões de autocompletar enquanto você programa.

Comence a usar o GitHub Copilot

Adicionar colaboradores a este repositório

Pesquise pessoas usando seu nome de usuário do GitHub ou endereço de e-mail.

Convide colaboradores

Configuração rápida — se você já fez algo parecido antes.

Configurar no computador ou HTTPS SSH https://github.com/jeffersonferreira.fagundes-eng/MVP-Engenharia-de-Dados-Novo.git

Comence criando um novo arquivo ou enviando um arquivo existente. Recomendamos que todos os repositórios incluam um arquivo README, um arquivo LICENSE e um arquivo .gitignore.

...ou crie um novo repositório na linha de comando.

```
echo "# MVP-Engenharia-de-Dados-Novo" >> README.md
git init
git add README.md
git commit -m "primeiro commit"
```

Figura A.20 - Documentação da data_quality_summary e evidência do GitHub.




Figura A.22 - Organização dos notebooks no repositório GitHub.

- w
- me
- rn
- workspace
- cents
- talog
- js & Pipelines
- mpute
- cover
- arketplace
- L Editor
- eries
- shboards
- nie Agents
- rts
- ery History
- L Warehouses
- gineering
- ns

Workspace

- > Home
- > Shared with me
- > Workspace
- ☆ Favorites
- 🗑️ Trash

Workspace > Users > jefersonferreira.fagundes@gmail.com > MVP-Engenharia-de-Dados-New

main

notebooks ☆

Send feedback

Share

Create

Search

Type

Owner

Last modified

Name	Type	Owner	Created at	Last updated at
00_setup	Notebook	jefersonferreira.f...	Sep 04, 2026, 03:...	Sep 04, 2026, 03:52 PM
01_bronze_ingestion	Notebook	jefersonferreira.f...	Sep 04, 2026, 03:...	Sep 04, 2026, 03:52 PM
02_silver_quality	Notebook	jefersonferreira.f...	Sep 04, 2026, 03:...	Sep 04, 2026, 03:52 PM
03_gold_analysis	Notebook	jefersonferreira.f...	Sep 04, 2026, 03:...	Sep 04, 2026, 03:52 PM
04_catalog_lineage	Notebook	jefersonferreira.f...	Sep 04, 2026, 03:...	Sep 04, 2026, 03:52 PM
README.md	File	jefersonferreira.f...	Sep 04, 2026, 03:...	-

Apêndice B - Evidências de versionamento e integração Git

As evidências a seguir registram a organização final do projeto no GitHub e a integração do repositório com o Databricks por meio de Git folder (funcionalidade anteriormente denominada Repos). O repositório foi associado à branch main, os notebooks do pipeline foram disponibilizados na pasta notebooks e a documentação final foi versionada na pasta docs.

github.com/jefersonferreirafagundes-eng/MVP-Engenharia-de-Dados-New

inglês português Google Translate

jefersonferreirafagundes-eng / MVP-Engenharia-de-Dados-New

Issues Pull requests Actions Projects Wiki Security and quality Insights Settings

MVP-Engenharia-de-Dados-New Public

Pin Watch 0 Fork 0 Star 0

main 1 Branch 0 Tags

Go to file Add file Code

jefersonferreirafagundes-eng README.md d90dbca - 4 hours ago 6 Commits

images	Create README.md	last week
notebooks	Add files via upload	last week
README.md	README.md	há 4 horas

README

MVP de Engenharia de Dados

Fatores associados à nota final dos estudantes

About

MVP de Engenharia de Dados no Databricks com PySpark, Delta Lake, Unity Catalog e arquitetura Medalhão para análise de fatores associados ao desempenho acadêmico.

Readme Activity 0 stars 0 watching 0 forks

Releases

No releases published [Create a new release](#)

Packages

No packages published

Figura B.1 - Estrutura do repositório MVP-Engenharia-de-Dados-New no GitHub.

Workspace

Home

Shared with me

Workspace

Favorites

Trash

Workspace

Users

jefersonferreira.fagundes@gmail.com

MVP-Engenharia-de-Dados-New

main

notebooks

☆

Search

Type

Owner

Last modified

00_setup

Notebook

jefersonferreira.f...

Sep 04, 2026, 03:...

Sep 04, 2026, 03:52 PM

01_bronze_ingestion

Notebook

jefersonferreira.f...

Sep 04, 2026, 03:...

Sep 04, 2026, 03:52 PM

02_silver_quality

Notebook

jefersonferreira.f...

Sep 04, 2026, 03:...

Sep 04, 2026, 03:52 PM

03_gold_analysis

Notebook

jefersonferreira.f...

Sep 04, 2026, 03:...

Sep 04, 2026, 03:52 PM

04_catalog_lineage

Notebook

jefersonferreira.f...

Sep 04, 2026, 03:...

Sep 04, 2026, 03:52 PM

README.md

File

jefersonferreira.f...

Sep 04, 2026, 03:...

-

Send feedback

Share

Create

Figura B.2 - Git folder no Databricks, branch main, com os cinco notebooks do pipeline.




Figura B.3 - Pasta docs sincronizada no Databricks contendo README.md e o relatório final em PDF.

Com essas evidências, o repositório GitHub, os scripts/notebooks e a documentação final estão reunidos em um fluxo versionado e sincronizado com o Databricks, complementando as evidências técnicas de ingestão, qualidade, modelagem, catálogo e linhagem apresentadas no Apêndice A.